Model Penelitian dan Pengembangan untuk GELITA

Rekomendasi, alasan, pemetaan ke peta jalan Revisi 10, dan ringkasan teori — setiap rujukan dicek ke sumber asli

---

Tanggal: 26 Oktober 2026, diperbarui 1 November 2026 · **Status:** model diganti ADDIE oleh peneliti 1 November 2026 (bagian *Pembaruan 1 November 2026*); sebelumnya diputuskan pengembang 26 Oktober 2026 (model Plomp dan aturan I-CVI Lynn; diperbarui hari yang sama dengan keputusan empat usulan di bagian 8 dan 9: uji beda eksploratif, kepraktisan, fase penelitian pendahuluan dengan lembar L8, nomor prototipe I–III), tercatat di `04_CATATAN_KEPUTUSAN.md` · **Jenis:** bacaan pendukung untuk peneliti dan tim, bukan dokumen implementasi · **Disusun:** AI, dari dokumen di repositori dan sumber asli
Judul penelitian: *Pengembangan Game Edukasi Etnopedagogi Kedu Berbasis Analitik sebagai Model Asesmen Literasi Digital Peserta Didik Sekolah Dasar*

Pembaruan 1 November 2026: model ADDIE

> **Keputusan peneliti (1 November 2026)**
>
> Penelitian ini memakai **model penelitian dan pengembangan ADDIE** (*Analyze*, *Design*, *Develop*, *Implement*, *Evaluate*; Branch, 2009), menggantikan model Plomp (2013) yang diputuskan pengembang 26 Oktober 2026. Alasannya: setiap fase pengembangan diuji, dan perubahan dari saran ahli atau hasil uji masuk kembali ke fase pengembangan sampai produknya benar-benar final. Keputusan ini dan akibatnya tercatat di `04_CATATAN_KEPUTUSAN.md` (1 November 2026).
>
> Bagian 1, 4, 5, dan 7 di bawah dipertahankan sebagai catatan analisis 26 Oktober 2026. Bagian 2, 3, 6, dan 8–13 tetap berlaku, kecuali bila disebut lain di bagian ini.

Apa kata sumbernya

Branch (2009) menyebut ADDIE "a product development paradigm and not a model per se" (hlm. 1), bersifat iteratif dan nonlinier, dengan uji rintis (*pilot test*) di fase *Develop* (lihat bagian 6 dan 11). Jadi pola "uji, revisi, uji lagi" yang diminta peneliti memang ada di sumber aslinya, dan kritik "ADDIE tidak menjelaskan cara mengevaluasi prototipe" terlalu keras (bagian 11). Satu kritik di bagian 6 tetap benar: ADDIE tidak memberi kriteria mutu khusus untuk instrumen asesmen atau bukti validitas.

Bagaimana kekurangan itu ditutup

- **Metode di dalam fase tidak berubah.** ECD tetap cara merancang asesmen (bagian 5.4); lapis evaluasi formatif Tessmer (1993) dan tabel metode Nieveen & Folmer (2013) tetap menentukan cara menguji setiap prototipe, kini di fase *Develop*; aturan I-CVI Lynn, V Aiken, κ, dan model Rasch tetap (bagian 9 dan 10).
- **Empat kriteria mutu tetap dipakai** sebagai kriteria mutu produk, tidak bergantung pada model pengembangan: relevansi, konsistensi, kepraktisan, dan keefektifan (Plomp, 2013, hlm. 29; bagian 8). Keefektifan tetap diartikan sebagai mutu pengukuran, bukan peningkatan hasil belajar.
- **Uji coba dipisah dari pengambilan data utama.** Kritik bagian 6 bahwa *Implement* menggabungkan uji coba dengan pengambilan data utama diatasi dengan menaruh uji kelompok kecil dan menengah di fase *Develop*, dan uji besar di fase *Implement* pada versi yang dikunci di G4.
- **Keluaran di luar alat ukur** ditulis sebagai rekomendasi pengembangan asesmen berbasis game untuk anak, bukan prinsip desain (bagian 5.6 adalah keluaran khas model Plomp).

Pemetaan peta jalan GELITA ke ADDIE

Menggantikan bagian 7. Nama metode mengikuti Tessmer (1993; telaah ahli, satu-satu, kelompok kecil, uji lapangan) dan Nieveen & Folmer (2013, Tabel 2, hlm. 162).

Fase ADDIE	Tahap GELITA (gerbang)	Prototipe	Metode evaluasi formatif	Kriteria utama	Bukti utama
Analyze	Sebelum tahap 1	—	Kajian pustaka, telaah produk lama, analisis konteks sekolah (L8)	Relevansi	Konstruk D1–D3, peta bukti, 05, 10, L8
Design	1 Desain instrumen (G1)	Prototipe I (draf): bank, instrumen, mock-up	*Screening*: telaah pendahuluan berbantuan AI (09, 10)	Relevansi, konsistensi	Daftar periksa; cacat jelas dibetulkan sebelum ke ahli
Develop	2 Validasi ahli dan izin etik (G2)	Prototipe I, direvisi	Telaah ahli (*expert appraisal*): sebelas validator, penilaian ulang tanpa batas putaran sampai butir lolos; *micro-evaluation*: uji keterbacaan dengan 4 + 1 anak (KG1)	Relevansi, konsistensi, kepraktisan diharapkan	V Aiken, I-CVI (aturan Lynn), S-CVI/Ave; κ berbobot pelabelan buta ≥ 0,70
Develop	3 Implementasi (G3)	Prototipe II: instalasi uji	*Walkthrough*: ahli media langkah 2; *screening*: tes otomatis	Konsistensi, kepraktisan diharapkan	Instrumen media, uji delapan perangkat
Develop	4 Uji coba bertahap (G4)	Prototipe III: lengkap, direvisi setelah setiap uji	Satu-satu: berpikir lantang (KG2, 5–8 anak); kelompok kecil: uji kelompok kecil (KG3a, 8–12 anak, lima pertemuan); uji lapangan formatif / *try-out*: uji kelompok menengah (KG3b, ± 80 siswa)	Kepraktisan nyata; keefektifan diharapkan	Protokol berpikir lantang, κ L4 ≥ 0,60, angka butir awal, penetapan ambang waktu; versi dikunci dan pra-registrasi OSF
Implement	5 Pengambilan data utama (G5)	Versi final yang dikunci di G4	Uji besar: target 300 siswa yang datanya bisa dianalisis, sekitar enam sekolah utama; hanya perbaikan kerusakan teknis yang dicatat	Kepraktisan dan keefektifan nyata	Log game dan lembar L0–L8
Evaluate	Setiap fase; 6 Analisis dan pelaporan	—	Evaluasi formatif di setiap fase (baris di atas); evaluasi sumatif: analisis data utama	Semua	Rasch, DIF, pola kesalahan, validitas kriteria; rekomendasi pengembangan

Uji kelompok kecil dan menengah dilakukan di sekolah uji coba berawalan `U` di wilayah Kedu, di luar sekolah utama, dan datanya tidak masuk analisis utama. Satu anak hanya ikut satu uji.

Untuk Bab III

- Rujuk Branch (2009) untuk ADDIE dan sifatnya yang iteratif; rujukan Plomp (2013) tetap dipakai hanya untuk empat kriteria mutu, dan Tessmer (1993) serta Nieveen & Folmer (2013) untuk metode evaluasi formatif.
- Tulis setiap putaran revisi dengan prototipe yang direvisi (misalnya "Prototipe III, revisi setelah uji kelompok kecil"), seperti yang sudah dicatat di 04.
- Bagian 5.7 (pemakaian di Indonesia) berlaku untuk Plomp. Contoh pemakaian ADDIE di jurnal Indonesia dicari dan dirujuk langsung oleh peneliti, di luar dokumen ini (1 November 2026).

1. Ringkasan

> **Keputusan (26 Oktober 2026; model diganti ADDIE 1 November 2026)**
>
> Penelitian ini memakai **penelitian desain pendidikan (*educational design research*) model Plomp (2013), jenis studi pengembangan (*development study*)**. Di dalam model itu:
>
> - **Evidence-Centered Design (ECD)** menjadi metode merancang asesmennya (Mislevy, Steinberg, & Almond, 2003);
> - **lapis evaluasi formatif Tessmer (1993)** dan **tabel metode evaluasi formatif Nieveen & Folmer (2013)** menentukan cara menguji setiap prototipe;
> - **empat kriteria mutu**, yaitu relevansi, konsistensi, kepraktisan, dan keefektifan (Plomp, 2013, hlm. 29), menjadi ukuran mutu produk.
>
> Peta jalan enam tahap dan lima gerbang di dokumen 01 sudah mengikuti pola model ini; sebelum keputusan ini yang belum ada hanya namanya. Sebelumnya tidak ada dokumen di `docs/` yang menyebut model pengembangan apa pun (dicek: ADDIE, 4D, Borg & Gall, Sugiyono, Plomp, McKenney, Nieveen, Tessmer, Richey, MDLC, GDLC).

Setiap rujukan dan klaim di dokumen ini dicek ke sumber aslinya, bukan ditulis dari ingatan. Bagian 11 merangkum 14 rincian yang mudah keliru dikutip. Bagian 12 mencatat rujukan di dokumen Revisi 10 yang dibetulkan berdasarkan pengecekan ini.

2. Cara pengecekan

Setiap rujukan dicek pada 26 Oktober 2026. Sumber yang dipakai berurutan dari yang paling kuat: teks lengkap aslinya (PDF terbuka, ERIC, salinan penulis, pindaian buku), lalu catatan penerbit, DOI di Crossref, atau katalog perpustakaan, dan terakhir sumber sekunder yang mengutipnya. Kutipan inti untuk rekomendasi, yaitu tahapan dan kriteria Plomp (2013) serta tabel metode Nieveen & Folmer (2013), dicek dua kali langsung di PDF resmi SLO. Setiap rujukan di daftar pustaka diberi tanda tingkat pengecekan:

Tanda	Arti
A	Teks asli dibaca: PDF lengkap, pindaian, atau versi laporan penulis dengan isi yang sama. Nomor halaman diambil dari sumber itu.
C	Cuplikan teks asli lewat pencarian teks penuh pada pindaian buku di archive.org. Kata-kata aslinya terlihat, tetapi nomor halaman diambil dari daftar isi, indeks, atau judul halaman buku.
K	Catatan penerbit, DOI/Crossref, atau katalog perpustakaan. Data bibliografinya pasti; isinya dicek lewat abstrak atau deskripsi penerbit.
S	Isi klaim hanya dari sumber sekunder yang mengutipnya. Di teks, klaim seperti ini selalu disebut sumber sekundernya.

3. GELITA sebagai penelitian pengembangan

Pilihan model ditentukan oleh sifat penelitiannya. Fakta berikut diambil dari dokumen Revisi 10 di repositori.

1. **Produknya ganda.** GELITA adalah game sekaligus instrumen asesmen. Judulnya menyebut game itu "sebagai Model Asesmen Literasi Digital". Mutu produk harus mencakup mutu media dan mutu pengukuran.
2. **Klaim utamanya soal pengukuran, bukan peningkatan hasil belajar.** Rencana analisis di 01 memakai model Rasch per dimensi, peta Wright, perbandingan model satu dimensi dan multidimensi, DIF antarvariasi a/b, κ, dan korelasi dengan tes awal–akhir. Tidak ada kelompok kontrol, dan tidak ada klaim bahwa game meningkatkan literasi.
3. **Pekerjaannya sudah berjalan dalam putaran bergerbang:** dokumen desain (06, 08, 11, 12) → telaah pendahuluan berbantuan AI (09, 10) → validasi tujuh ahli (V Aiken, I-CVI, S-CVI/Ave, pelabelan buta dengan $\kappa \geq 0{,}70$) dan uji keterbacaan dengan beberapa anak di luar sampel → implementasi → telaah ahli media langkah 2 → berpikir lantang 5–

8 siswa dan uji coba satu kelas → pembekuan dan pra-registrasi di OSF (G4) → pengambilan data utama (target 300 siswa yang datanya bisa dianalisis, dari sekitar 360 yang direkrut) → analisis.

4. **Ada batasan yang tetap:** sistem baru tidak diubah sebelum gerbang G2, termasuk persetujuan etik. Jadi prototipe yang dinilai ahli pertama kali berupa dokumen dan mock-up.
5. **Guru tidak ikut dalam penelitian.** Semua pengamatan dilakukan peneliti lewat lembar L0–L8.
6. **Setiap keputusan dicatat** di `04_CATATAN_KEPUTUSAN.md`, terbaru di atas.

4. Model yang dipakai: Plomp (2013)

Plomp (2013) membedakan penelitian desain sebagai *development studies* dan *validation studies* (hlm. 16; Tabel 1 di hlm. 23 menambahkan *implementation studies*). GELITA termasuk studi pengembangan. Untuk jenis ini Plomp menetapkan tiga fase (hlm. 19):

- **Penelitian pendahuluan** (*preliminary research*): analisis kebutuhan dan konteks, kajian pustaka, dan penyusunan kerangka konseptual atau teoretis.
- **Fase pengembangan atau pembuatan prototipe** (*development or prototyping phase*): beberapa iterasi. Setiap iterasi adalah siklus mikro penelitian, dengan evaluasi formatif sebagai kegiatan penelitian terpenting.
- **Fase penilaian** (*assessment phase*): evaluasi semi-sumatif untuk menyimpulkan apakah intervensi memenuhi spesifikasi yang ditetapkan sebelumnya.

> "Throughout all these activities, the researcher or research group will do systematic reflection and documentation to produce the theories or design principles" — Plomp (2013, hlm. 19)

Kriteria mutu. Plomp (2013, hlm. 29, Tabel 2, diadaptasi dari Nieveen, 1999) memakai empat kriteria. Pembedaan "diharapkan" dan "nyata" berasal dari Nieveen & Folmer (2013, hlm. 160–161).

Kriteria	Arti menurut Plomp (2013, hlm. 29)
Relevansi (validitas isi)	Intervensi memang dibutuhkan, dan rancangannya berdasar pengetahuan ilmiah terkini.
Konsistensi (validitas konstruk)	Intervensi dirancang secara "logis".
Kepraktisan: diharapkan / nyata	Intervensi diharapkan dapat dipakai / terbukti dapat dipakai di lingkungan yang menjadi sasarannya.
Keefektifan: diharapkan / nyata	Pemakaian intervensi diharapkan / terbukti memberi hasil yang diinginkan.

Kriteria ini bertingkat. Plomp bertanya: kalau intervensi tidak praktis, untuk apa meneliti keefektifannya? Kalau tidak konsisten, untuk apa meneliti kepraktisannya? (hlm. 29). Karena itu tiap fase menekankan kriteria yang berbeda (Tabel 3, hlm. 30). Penelitian pendahuluan menekankan relevansi. Fase prototipe mulai dari konsistensi dan kepraktisan, lalu bergeser ke keefektifan. Fase penilaian menekankan kepraktisan dan keefektifan.

Metode evaluasi formatif. Plomp mengambil lapis evaluasi formatif dari Tessmer (1993) (Gambar 5, hlm. 36). Tessmer menyebut empat jenis klasik: telaah ahli, satu-satu, kelompok kecil, dan uji lapangan. Evaluasi diri ia golongkan sebagai jenis telaah ahli; kelimanya digambar sebagai lapis (Tessmer, 1993, Gambar 2.3, hlm. 35). Nieveen & Folmer (2013, hlm. 159–162) memasangkan metode dengan tahap prototipe:

Kriteria	Usulan desain	Desain global	Sebagian rinci	Lengkap
Relevansi, konsistensi	screening, focus group	screening, focus group	screening, focus group	screening, focus group
Kepraktisan/keefektifan diharapkan	screening, focus group	screening, focus group	focus group (+ walkthrough untuk kepraktisan)	focus group (+ walkthrough untuk kepraktisan)
Kepraktisan/keefektifan nyata	—	—	micro-evaluation	micro-evaluation, try-out

Sumber: Nieveen & Folmer (2013), Tabel 2, hlm. 162. Arti metodenya (hlm. 161–162): *screening* = tim desain memeriksa rancangan dengan daftar periksa; *focus group* (juga disebut *expert appraisal*) = sekelompok responden menanggapi prototipe; *walkthrough* = tim desain dan wakil kelompok sasaran menelusuri prototipe bersama; *micro-evaluation* = sekelompok kecil pengguna memakai sebagian produk di luar situasi pemakaian normal; *try-out* = kelompok sasaran memakai produk dalam praktik.

5. Alasan memilih model Plomp

5.1 Bentuknya sama dengan peta jalan GELITA

Tahap 1–4 di peta jalan adalah iterasi fase prototipe, tahap 5–6 adalah fase penilaian, gerbang G1–G5 adalah titik keputusan antariterasi, dan dokumen 04 adalah "refleksi dan dokumentasi sistematis" yang diminta Plomp (hlm. 19). Rencana tidak perlu diubah; yang berubah hanya label dan cara melaporkannya.

5.2 Kriterianya cocok untuk produk yang berupa alat ukur

Model R&D yang berorientasi pembelajaran, seperti uji lapangan utama Borg & Gall, menilai produk dari hasil belajar sebelum dan sesudah. GELITA tidak mengklaim itu. Di Plomp, keefektifan berarti "pemakaian intervensi memberi hasil yang diinginkan" (hlm. 29). Untuk model asesmen, hasil yang diinginkan adalah pengukuran yang sahih dan andal. Jadi keefektifan GELITA bisa diukur dengan jujur lewat kecocokan Rasch, reliabilitas, urutan wilayah di peta Wright, dan korelasi dengan tes luar (lihat bagian 8). Validitas juga sudah dipecah menjadi relevansi (isi) dan konsistensi (konstruk), sejalan dengan bukti validitas yang dikumpulkan GELITA.

5.3 Prototipe awal boleh berupa kertas, sesuai batasan "sistem diubah setelah G2"

> "Early prototypes can be just paper-based for which the formative evaluation takes place via expert judgments resulting in expected practicality" — Plomp (2013, Tabel 3, hlm. 30)

Inilah situasi tahap 2 GELITA: ahli menilai dokumen, game yang ada sekarang, dan mock-up layar baru sebelum ada perubahan sistem. Model lain tidak secara terang mengatur kasus ini.

5.4 ECD masuk wajar ke fase prototipe

ECD adalah cara merancang asesmen, bukan model R&D, jadi ia membutuhkan "wadah". Model Plomp memberi wadah itu tanpa bertabrakan. Unsur ECD dan padanannya di GELITA:

Unsur ECD	Sumber	Padanan di GELITA
Model siswa (*student model*)	Mislevy dkk. (2003, hlm. 22)	Literasi digital tiga dimensi D1–D3 (01)
Model bukti: aturan bukti + model statistik	Mislevy dkk. (2003, hlm. 6)	10 analitik dan kamus data `kamus-1.0` (11); model Rasch multidimensi *between-item*
Model tugas (*task model*)	Mislevy dkk. (2003, hlm. 22)	Lima jenis tantangan: Susun Gambar, Isi Rumpang, Benar atau Salah, Cari Objek, Skenario Digital
Model perakitan (*assembly model*)	Mislevy dkk. (2003, hlm. 22)	Variasi a/b, buklet, butir jangkar, lima pertemuan (06)
Model presentasi dan model penyampaian (*delivery model*)	Almond dkk. (2002, hlm. 12–13)	Layar game, token sesi, mode penelitian
Empat proses: pemilihan aktivitas, presentasi, pemrosesan respons, skor ringkasan	Almond dkk. (2002, hlm. 5); Mislevy dkk. (2003, hlm. 55–56)	Benar/salah dan bintang dihitung di server; kunci jawaban tidak pernah dikirim ke peramban
Lima lapis ECD: analisis ranah, pemodelan ranah, CAF, implementasi, penyampaian	Mislevy & Haertel (2006, hlm. 7)	Penelitian pendahuluan → tahap 1 (CAF) → tahap 3 (implementasi) → tahap 5 (penyampaian)

Pemakaian ECD di dalam game juga punya preseden. *Stealth assessment* Shute (2011) menjadikan ECD salah satu dari dua unsur kunci asesmen yang "dijalin langsung ke dalam lingkungan pembelajaran", dengan data kinerja dikumpulkan terus-menerus selama bermain (hlm. 504–505).

5.5 Setiap putaran uji punya nama dan dasar

Semua putaran yang sudah direncanakan GELITA punya padanan resmi di tabel Nieveen & Folmer (2013). Telaah pendahuluan berbantuan AI adalah *screening*. Validasi tujuh ahli adalah *focus group/expert appraisal*. Telaah ahli media pada layar jadi adalah *walkthrough*. Uji keterbacaan dan berpikir lantang adalah *micro-evaluation*/evaluasi satu-satu. Uji coba satu kelas adalah *try-out*. Penguji bisa melihat alasan setiap putaran, dan pemetaan lengkapnya ada di bagian 7.

5.6 Keluarannya dua: produk dan prinsip desain

Plomp menyebut dua keluaran utama studi pengembangan: intervensi berbasis penelitian dan prinsip desain yang bisa dipakai ulang (Tabel 1, hlm. 23; hlm. 35). Inilah yang membuat kata "model" di judul bisa dipertanggungjawabkan sebagai sumbangan teoretis. Format prinsip desain dari van den Akker (1999, hlm. 9, dikutip Plomp, 2013, hlm. 24):

> "If you want to design <intervention X> for the <purpose/function Y> in <context Z>, then you are best advised to give <that intervention> the <characteristics A, B, and C> [substantive emphasis], and to do that via <procedures K, L, and M> [procedural emphasis], because of <arguments P, Q, and R>." — van den Akker (1999), dalam Plomp (2013, hlm. 24)

Calon prinsip desain sudah ada di catatan keputusan, misalnya:

- topik Skenario Digital sama di tiap wilayah dan kerumitannya yang naik, supaya topik tidak tercampur dengan tingkat kesulitan;
- yang dinilai adalah percobaan pertama, sedangkan kesempatan berikutnya untuk belajar;
- kunci jawaban dan penilaian tetap di server;
- bacaan dan pernyataan D1 tidak dibacakan, supaya yang terukur tetap kemampuan membaca.

5.7 Sudah dikenal di Indonesia

Plomp (2013, hlm. 26) memakai penelitian desain Fauzan di Indonesia sebagai contoh. Lima artikel jurnal Indonesia yang halamannya dibuka menyebut model Plomp sebagai model pengembangannya: Ferita & Retnawati (2016), Djidu & Jailani (2018), Siregar dkk. (2021), Fitrianty dkk. (2022), dan Wardhani (2024). Sebagian besar di bidang pendidikan matematika. Ini cukup untuk menyebut model Plomp "sering dipakai", tetapi bukan hitungan sistematis. Catatan: sebagian penelitian Indonesia merujuk Plomp 2010 atau menyebut empat sampai lima fase. Rujuk Plomp (2013) secara langsung supaya fasenya jelas.

6. Mengapa bukan model lain

Model	Isi menurut sumber aslinya	Kecocokan dengan GELITA
ADDIE Branch (2009)	Analyze, Design, Develop, Implement, Evaluate. Branch menyebutnya "a product development paradigm and not a model per se" (hlm. 1), bersifat iteratif dan nonlinier, dengan uji rintis (*pilot test*) di fase Develop.	Bisa dipetakan, tetapi umum sekali. Tidak memberi kriteria mutu untuk instrumen asesmen atau bukti validitas, dan Implement menggabungkan uji coba dengan pengambilan data utama. Aman di mata penguji, tetapi tidak menambah apa pun pada argumen pengukuran.
4D Thiagarajan dkk. (1974)	Define (analisis awal-akhir, peserta didik, tugas, konsep, perumusan tujuan; hlm. 6), Design (hlm. 7), Develop (telaah ahli dan uji pengembangan; hlm. 8), Disseminate (uji validasi, pengemasan, difusi dan adopsi; hlm. 9). Awalnya untuk bahan pelatihan guru anak berkebutuhan khusus.	Develop cocok dengan tahap 2–4, dan uji validasi di Disseminate bisa menampung pengambilan data utama. Namun pengemasan, difusi, dan adopsi di luar rencana; Define berorientasi tujuan pembelajaran; dan tidak ada kriteria mutu untuk alat ukur atau keluaran teoretis.
Borg & Gall (1983, hlm. 775–776)	Sepuluh langkah, dari pengumpulan informasi sampai diseminasi, dengan tiga uji lapangan (awal, utama, operasional). Uji lapangan utama mengumpulkan data kuantitatif sebelum dan sesudah, dan hasilnya dibandingkan dengan kelompok kontrol "when appropriate". Angka sekolah dan subjek (mis. 5–15 sekolah, 30–100 subjek) adalah praktik proyek *minicourse* Far West Laboratory, bukan aturan umum.	Paling dekat dengan rangkaian uji lapangan GELITA, tetapi GELITA hanya punya satu uji coba dan satu pengambilan data utama. Langkah 7–10 (revisi operasional, uji lapangan operasional, revisi akhir, diseminasi) tidak ada, jadi penelitian berhenti di langkah 6 dan harus dijelaskan. Bisa jadi cadangan kalau program studi mewajibkannya. Jangan rujuk edisi 2003 (Gall, Gall, & Borg) untuk sepuluh langkah ini: edisi itu tampaknya memakai siklus berbasis Dick & Carey.

Model	Isi menurut sumber aslinya	Kecocokan dengan GELITA
Sugiyono (2013, hlm. 298)	Sepuluh langkah: potensi dan masalah, pengumpulan data, desain produk, validasi desain, revisi desain, uji coba produk, revisi produk, uji coba pemakaian, revisi produk, produksi masal. Contoh di babnya dari bidang manajemen.	Diakhiri produksi masal, yang tidak relevan untuk GELITA, dan tidak mengatur bukti validitas alat ukur.
MDLC dan GDLC Luther (1994); Ramadan & Widyani (2013)	Luther: Concept, Design, Collecting Content Material, Assembly, Testing, Distribution; nama "MDLC" diberikan kemudian. GDLC: initiation, pre-production, production, testing, beta, release (fase dari sumber sekunder Aleem dkk., 2016).	Siklus produksi perangkat lunak, bukan desain penelitian. Paling jauh hanya menggambarkan kerja internal tahap 3.
McKenney & Reeves (2019)	Analisis dan eksplorasi, desain dan konstruksi, evaluasi dan refleksi, dikelilingi implementasi dan penyebaran; keluaran ganda (intervensi dan pengetahuan).	Satu keluarga dengan Plomp, tetapi kurang preskriptif. Cocok sebagai rujukan pendukung untuk keluaran ganda.
Richey & Klein (2007)	Dua jenis penelitian desain dan pengembangan: penelitian produk dan alat, dan penelitian model.	Label alternatif yang sah (GELITA masuk penelitian produk dan alat), tetapi kurang operasional untuk menyusun tahapan.

7. Pemetaan peta jalan GELITA ke model Plomp

Tahap GELITA (gerbang)	Fase Plomp	Prototipe (tahap Nieveen & Folmer)	Metode evaluasi formatif	Kriteria utama	Bukti utama
Sebelum tahap 1 (sudah ada di 01, 05, 10, dan game kelas 5 sekarang)	Penelitian pendahuluan (fase tersendiri, diputuskan 26 Oktober 2026)	Menghasilkan usulan desain	Kajian pustaka, telaah produk lama, analisis konteks sekolah	Relevansi	Konstruk D1–D3, peta bukti, telaah butir lama (05), telaah media pendahuluan (10), L8 Profil sekolah per sekolah sasaran (02)
1 Desain instrumen (G1)	Prototipe, iterasi 1	Prototipe I: usulan desain → desain global (06, 08, 11, 12, mock-up)	*Screening* / evaluasi diri: telaah pendahuluan berbantuan AI (09, 10)	Relevansi, konsistensi	Daftar periksa; cacat jelas dibetulkan sebelum ke ahli
2 Validasi ahli dan izin etik (G2)	Prototipe, iterasi 2	Prototipe I, lanjutan (berbasis kertas dan mock-up)	*Focus group/expert appraisal*: tujuh ahli; *micro-evaluation*: uji keterbacaan dengan beberapa anak di luar sampel	Relevansi, konsistensi, kepraktisan diharapkan	V Aiken, I-CVI, S-CVI/Ave; κ berbobot pelabelan buta ≥ 0,70
3 Dokumen implementasi dan perubahan sistem (G3)	Prototipe, iterasi 3	Prototipe II: sebagian rinci → lengkap (instalasi uji)	*Walkthrough*: ahli media langkah 2; *screening*: tes otomatis	Konsistensi, kepraktisan diharapkan	Instrumen media, uji delapan perangkat
4 Uji coba satu kelas (G4)	Prototipe, iterasi 4	Prototipe III: lengkap	*Micro-evaluation*/satu-satu: berpikir lantang 5–8 siswa; *try-out*: satu kelas dengan semua lembar	Kepraktisan nyata; keefektifan diharapkan	Protokol berpikir lantang, κ L4 ≥ 0,60, penetapan ambang waktu; pra-registrasi OSF
5 Pengambilan data utama (G5)	Penilaian (semi-sumatif)	Produk final (sesudah Prototipe III)	*Try-out* skala penuh / uji lapangan	Kepraktisan dan keefektifan nyata	Log game dan lembar L0–L8, sekitar 300 siswa
6 Analisis dan pelaporan	Penilaian + refleksi	Produk dan prinsip desain	—	Semua	Rasch, DIF, pola kesalahan, validitas kriteria; prinsip desain

8. Kriteria mutu yang diterjemahkan untuk GELITA

Kriteria	Arti untuk GELITA sebagai model asesmen	Bukti yang sudah direncanakan
Relevansi	Butir dan tugas mewakili konstruk literasi digital D1–D3 dan konteks budaya Kedu.	I-CVI, V Aiken, S-CVI/Ave dari panel ahli materi; ahli budaya Kedu; kisi-kisi 06
Konsistensi	Rantai klaim–bukti–tugas ECD utuh; label dimensi dan level AKM disepakati ahli.	Peta bukti, kamus data 11, κ berbobot pelabelan buta ≥ 0,70
Kepraktisan	Diharapkan: ahli menilai game bisa dipakai di perangkat dan kelas sasaran. Nyata: game berjalan di perangkat sekolah, sesi muat dalam waktu, dan siswa bisa bermain tanpa bantuan isi soal.	Uji delapan perangkat, telaah ahli media; log penyelesaian, "dilewati", waktu aktif; L1 (kondisi sesi), L3 (bantuan), L4 (keterlibatan); bintang 1–5 di kritik dan saran Balai Refleksi (`feedback_rating`, pendapat siswa). Diputuskan 26 Oktober 2026: cukup untuk sekarang; pertanyaan tambahan untuk siswa ditimbang setelah uji coba tahap 4, dengan berpikir lantang (L5) sebagai bahan kualitatif
Keefektifan	Skor game mengukur dengan baik.	Kecocokan Rasch (MNSQ 0,5–1,5 "productive for measurement"; Linacre, 2002); reliabilitas dan separasi; urutan wilayah di peta Wright; DIF antarvariasi; korelasi dengan tes awal–akhir (bukti validitas kriteria, kegunaan utama tes)

> **Catatan tentang uji beda tes awal–akhir (diputuskan 26 Oktober 2026)**
>
> Rencana analisis di 01 menyebut "uji beda tes awal dan akhir". Desain satu kelompok dengan tes awal dan akhir termasuk desain pra-eksperimen (Campbell & Stanley, 1963). Perubahannya bisa disebabkan sejarah dan kematangan (hlm. 7), efek tes dan instrumentasi (hlm. 9), serta pada beberapa kasus regresi statistik (hlm. 10). Tanpa kelompok kontrol, uji ini tidak bisa menunjukkan bahwa game menyebabkan perubahan. Usulannya: pakai tes awal–akhir terutama sebagai bukti validitas kriteria (korelasi dengan kemampuan Rasch), dan laporkan uji bedanya sebagai temuan eksploratif. **Pengembang menyetujui usulan ini (26 Oktober 2026).** Uji berpasangan, ukuran efek, dan model campuran tetap dilaporkan lengkap sebagai "perubahan" eksploratif; rencana analisisnya di `13_TES_AWAL_AKHIR.md`.

9. Yang perlu dilengkapi

1. **Sebut nama modelnya** di Bab III, berikut tabel pemetaan di bagian 7. Keputusannya sudah tercatat di 04.
2. **Penelitian pendahuluan sebagai fase tersendiri (diputuskan 26 Oktober 2026).** Plomp meminta analisis kebutuhan dan konteks, kajian pustaka, dan kerangka konseptual (hlm. 19). Bahannya sudah tersebar di 01, 05, 10, dan game kelas 5. Data konteks sekolah sasaran, yang tadinya tipis, diambil dari lembar baru L8 Profil sekolah di `02_LEMBAR_LAPANGAN.md` (draf): satu lembar per sekolah, berisi fakta sekolah (letak, rombel kelas 5, perangkat, internet, listrik, pengalaman ANBK, pelajaran digital), tanpa nama guru atau siswa. Penulisannya daftar kerja no. 22 di 01.
3. **Kepraktisan didefinisikan eksplisit (diputuskan 26 Oktober 2026).** Karena guru tidak ikut, kepraktisan diambil dari log, L1, L3, dan L4, ditambah pendapat siswa: bintang 1–5 "Seberapa senang kamu bermain GELITA?" di kritik dan saran Balai Refleksi (`feedback_rating`, `17_SKALA_SIKAP.md`). Pengembang memutuskan itu cukup untuk sekarang; perlu tidaknya pertanyaan tambahan untuk siswa diputuskan setelah uji coba tahap 4, dengan data berpikir lantang (L5) sebagai bahan kualitatif.
4. **Keefektifan sebagai mutu pengukuran,** dan uji beda tes awal–akhir eksploratif (diputuskan 26 Oktober 2026; lihat catatan di bagian 8).
5. **Nomor prototipe I, II, III (diputuskan 26 Oktober 2026),** mengikuti tabel di bagian 7: Prototipe I di tahap 1–2 (kertas dan mock-up), Prototipe II di tahap 3 (instalasi uji), Prototipe III di tahap 4 (uji coba), produk final di tahap 5. Tabelnya ada di peta jalan 01, dan setiap entri 04 yang merevisi produk menyebut prototipe yang direvisinya.
6. **Rumuskan prinsip desain** dengan format van den Akker di akhir penelitian.

7. **Aturan I-CVI: aturan Lynn (diputuskan 26 Oktober 2026).** Dengan lima ahli atau kurang, butir hanya lolos kalau semua ahli setuju (I-CVI = 1,00), seperti dikutip Polit & Beck (2006, hlm. 491). Aturan Polit, Beck, & Owen (2007, hlm. 466–467) yang lebih longgar tidak dipakai. Aturan itu menuntut kesepakatan sempurna hanya untuk tiga atau empat ahli, dan menerima butir bila I-CVI ≥ 0,78 dan S-CVI/Ave ≥ 0,90, dengan kappa termodifikasi k*. Akibatnya bagi GELITA: dengan lima ahli, empat setuju (I-CVI 0,80) berarti butir direvisi atau dibuang, walaupun menurut Polit dkk. butir itu "sangat baik" (k* = 0,76). Instrumen v2.1 menulis aturan ini terang-terangan di D.6.

10. Tabel ringkasan

A. Model penelitian dan pengembangan

Model	Fase	Kecocokan dengan GELITA	Putusan
Plomp (2013), EDR studi pengembangan	Penelitian pendahuluan → prototipe (iteratif, formatif) → penilaian (semi-sumatif); refleksi dan dokumentasi sepanjang jalan	Cocok dengan gerbang, klaim pengukuran, prinsip desain	**Dipakai**
McKenney & Reeves (2019)	Analisis/eksplorasi → desain/konstruksi → evaluasi/refleksi; implementasi dan penyebaran	Satu keluarga, kurang preskriptif	**Rujukan pendukung**
Richey & Klein (2007)	Penelitian produk dan alat / penelitian model	Label sah, kurang operasional	**Alternatif**
Borg & Gall (1983)	Sepuluh langkah, tiga uji lapangan	Dekat, tetapi langkah 7–10 tidak dipakai	**Cadangan bila diwajibkan**
Sugiyono (2013)	Sepuluh langkah, berakhir produksi masal	Tidak mengatur bukti validitas alat ukur	**Tidak disarankan**
4D, Thiagarajan dkk. (1974)	Define, Design, Develop, Disseminate	Develop cocok; pengemasan dan difusi kosong	**Tidak disarankan**
ADDIE, Branch (2009)	Analyze, Design, Develop, Implement, Evaluate	Umum, tanpa logika pengukuran	**Tidak disarankan**
Luther (1994); GDLC (2013)	Siklus produksi	Rekayasa saja	**Paling jauh di tahap 3**

B. Metode dan analisis

Tujuan	Metode	Kriteria atau statistik	Rujukan
Validitas isi	Penilaian ahli, skala relevansi 1–4	V Aiken; I-CVI; S-CVI/Ave ≥ 0,90; k*	Aiken (1985); Lynn (1986); Polit & Beck (2006); Polit dkk. (2007)
Kesepakatan label	Pelabelan buta oleh dua ahli	κ berbobot ≥ 0,70	Cohen (1960, 1968)
Mutu media	Heuristik, skala keparahan 0–4, uji perangkat	Rerata skor, aturan veto	Nielsen (1994a, 1994b); Wahono (2006); Leacock & Nesbit (2007)
Proses respons	Berpikir lantang; wawancara L5	Pengodean kualitatif	Ericsson & Simon (1993); AERA dkk. (2014)
Pengamatan	L4 adaptasi BROMP	κ ≥ 0,60 per skema	Ocumpaugh dkk. (2015)
Struktur internal	Rasch per dimensi, satu vs multidimensi, DIF a/b, butir jangkar	MNSQ 0,5–1,5; reliabilitas dan separasi; peta Wright	Bond & Fox (2015); Linacre (2002); Adams dkk. (1997)
Hubungan dengan variabel lain	Tes awal–akhir, metrik kata sandi	Korelasi	AERA dkk. (2014)
Kesempatan dan waktu	Model kejadian waktu-diskret dengan sensor; model campuran	—	Singer & Willett (2003)
Kesungguhan	Tanda tebakan cepat	*Response time effort*	Wise & Kong (2005)
Desain tes awal–akhir	Satu kelompok, tanpa kontrol	Eksploratif saja	Campbell & Stanley (1963)
Keterbukaan	Pra-registrasi OSF di G4	—	Nosek dkk. (2018)

C. Teori dan kerangka

Bidang	Teori atau kerangka	Peran di GELITA	Rujukan
Desain penelitian	EDR, kriteria mutu, evaluasi formatif, prinsip desain	Kerangka seluruh penelitian	Plomp (2013); Nieveen (1999); Nieveen & Folmer (2013); Tessmer (1993); van den Akker (1999)
Desain asesmen	Evidence-Centered Design	Model siswa, bukti, tugas, perakitan, penyampaian	Mislevy dkk. (2003); Almond dkk. (2002); Mislevy & Haertel (2006)
Asesmen dalam game	*Stealth assessment*	Bukti diambil dari permainan	Shute (2011); Shute & Ventura (2013)
Penyusunan ukuran	Empat blok bangunan (BEAR)	Peta konstruk, desain butir, ruang hasil (kode kesalahan, skor 0–1–2), model Rasch	Wilson (2005)
Validitas	Validitas terpadu; argumen interpretasi/penggunaan; lima sumber bukti	Kerangka bab validitas	Messick (1995); Kane (2013); AERA dkk. (2014)
Literasi digital	Empat pilar; DigComp 3.0	Dimensi D1–D3	Kominfo & Katadata (2023); Cosgrove & Cachia (2025); Gilster (1997)
Literasi membaca	Level AKM; empat proses PIRLS 2026	Level untuk D1	von Davier & Kennedy (2024)
Tingkat kognitif	Bloom revisi; DOK; SOLO	Label butir	Anderson & Krathwohl (2001); Webb (1999); Biggs & Collis (1982)
Etnopedagogi	Kearifan lokal sebagai sumber belajar; pengajaran responsif budaya	Isi budaya Kedu, D3	Alwasilah dkk. (2009); Gay (2018)
Pembelajaran berbasis game	Motivasi intrinsik; flow; prinsip belajar dalam game	Aturan tiga kesempatan, Serpihan Cahaya, cerita	Malone (1981); Malone & Lepper (1987); Csikszentmihalyi (1990); Gee (2003)
Multimedia	Teori kognitif pembelajaran multimedia	Aturan narasi, tata letak layar	Mayer (2021)
Umpan balik	Umpan balik formatif	Umpan balik setelah percobaan salah; analitik 9	Shute (2008); Hattie & Timperley (2007)
Analitik	Analitik pembelajaran untuk game	10 analitik, alur log	Freire dkk. (2016)

11. Rincian yang mudah keliru dikutip

Rumusan di kolom kiri sering ditulis dari ingatan, termasuk di draf awal dokumen ini. Kolom kanan adalah hasil cek ke sumber aslinya.

Rumusan yang keliru atau kurang tepat	Hasil cek ke sumber asli
Kriteria Nieveen: valid, praktis, efektif, masing-masing "diharapkan" lalu "nyata"	Tiga kriteria memang dari Nieveen (1999). Pembedaan diharapkan/nyata baru ada di Nieveen & Folmer (2013, hlm. 160–161); di Nieveen (1999) tidak ditemukan. Plomp (2013, hlm. 29) memecah validitas jadi relevansi dan konsistensi.
ADDIE "tidak menjelaskan cara mengevaluasi prototipe"	Terlalu keras. Branch (2009) memuat uji rintis di fase Develop dan menyebut ADDIE iteratif dan nonlinier. Yang tetap benar: tidak ada kriteria mutu khusus alat ukur.
4D: "Disseminate akan kosong"	Sebagian. Langkah pertamanya, uji validasi, adalah evaluasi sumatif dan bisa menampung pengambilan data utama. Yang kosong adalah pengemasan serta difusi dan adopsi (Thiagarajan dkk., 1974, hlm. 9).
Borg & Gall: uji lapangan utama "sering dengan kelompok kontrol"	Teksnya: dibandingkan dengan kelompok kontrol "when appropriate". Angka sekolah dan subjek adalah praktik proyek *minicourse* Far West Laboratory (Borg & Gall, 1983, hlm. 775–776).

Rumusan yang keliru atau kurang tepat	Hasil cek ke sumber asli
"Sugiyono (2015)" untuk sepuluh langkah	Sepuluh langkah ada di *Metode Penelitian Kuantitatif, Kualitatif, dan R&D*, Bab 16, Gambar 16.1, hlm. 298 (dicek pada cetakan 2013). Buku R&D 2015 belum terbukti memuat gambar itu.
"MDLC (Luther)"	Luther (1994) menulis enam langkah dengan nama "Collecting Content Material", bukan "material collecting". Nama MDLC diberikan kemudian.
ECD: "delivery model" dan lima lapis dari Mislevy dkk. (2003)	CAF di Mislevy dkk. (2003, hlm. 22) berisi lima model. Delivery Model ada di Almond dkk. (2002, hlm. 12–13). Lima lapis ECD dirumuskan di Mislevy & Haertel (2006, hlm. 7).
Infit/outfit 0,5–1,5 dirujuk ke Bond & Fox (2015)	Rujukan tepatnya Linacre (2002): "0.5 - 1.5 Productive for measurement".
Adams dkk. (1997) untuk model satu vs multidimensi	Rujukannya benar, tetapi istilah *between-item*/*within-item* hanya terkonfirmasi lewat sumber sekunder (Briggs & Wilson, 2003, hlm. 98).
Kominfo & Katadata (2022), pilar "Cakap/Etis/Aman/Budaya Bermedia Digital"	Diluncurkan Februari 2023. Laporannya memakai istilah Kecakapan Digital, Etika Digital, Keamanan Digital, dan Budaya Digital. Nama "... Bermedia Digital" adalah judul modul Kominfo tahun 2021.
Webb (1997) untuk level DOK	Webb (1997) hanya memuat kriteria "depth of knowledge consistency" (hlm. 15–17). Empat level bernomor (Recall, Skill/Concept, Strategic Thinking, Extended Thinking) ada di Webb (1999, hlm. 2).
Malone (1981) untuk motivasi intrinsik	Malone (1981) menyebut tiga: tantangan, fantasi, rasa ingin tahu. Kendali (*control*) ditambahkan Malone & Lepper (1987, hlm. 224).
Model Plomp "banyak dipakai di disertasi Indonesia"	Yang terbukti: sering dipakai di artikel jurnal pengembangan Indonesia, terutama pendidikan matematika. Klaim tentang disertasi tidak dicek.
"I-CVI = 1,00 untuk 3–5 ahli"	Benar menurut Lynn (1986), seperti dikutip Polit & Beck (2006, hlm. 491). Polit dkk. (2007) memakai aturan yang lebih longgar. GELITA memakai aturan Lynn (bagian 9, butir 7).

12. Koreksi rujukan di dokumen Revisi 10

Hal-hal ini ditemukan saat pengecekan dan sudah dibetulkan di dokumennya pada 26 Oktober 2026, kecuali baris terakhir yang memang sudah tepat.

Dokumen	Sebelumnya	Sekarang
01 (Cek fakta), 06 (rujukan)	von Davier, M., & Kennedy, A. M. (Eds.) (2024)	von Davier, M., & Kennedy, A. (Eds.) (2024), sesuai saran sitasi resminya, dengan DOI 10.6017/lse.tpisc.tr2103.kb4199
01, 05, 06 (rujukan)	*DigComp 3.0: The European Digital Competence Framework*	*DigComp 3.0: European Digital Competence Framework* (tanpa "The", sesuai baris "How to cite" laporannya), dengan DOI 10.2760/0001149
05, 06, 07 (rujukan)	Kominfo & Katadata Insight Center. (2022)	Tahun terbit 2023 (judulnya tetap "... 2022"), dengan istilah pilar dari laporannya: Kecakapan, Etika, Keamanan, Budaya Digital
01 (Pelevelan wilayah, rujukan)	"Depth of Knowledge Webb", dirujuk ke Webb (1997)	Webb (1997) tetap, dengan catatan; ditambah Webb (1999), Research Monograph No. 18, sebagai sumber level DOK. Judul rujukan "klasik, tidak dicek ulang" diganti menjadi "dicek ulang 26 Oktober 2026"
07 (Koreksi kecil)	Kriteria I-CVI "3–5 ahli: I-CVI = 1,00" (Lynn)	Keputusan memakai aturan Lynn ditambahkan; Polit dkk. (2007) masuk rujukan sebagai aturan yang tidak dipakai
07 (rujukan)	Cohen (1968): "Nominal scale agreement **with** provision for ..."	"Nominal scale agreement provision for scaled disagreement or partial credit" (judul asli, tanpa "with"), dengan DOI
02 (L4)	"adaptasi BROMP", tanpa sertifikasi	Sudah sesuai. Manual BROMP hanya membolehkan data disebut "BROMP" bila pengamatnya bersertifikat (hlm. 34), jadi sebutan "adaptasi" sudah tepat

13. Daftar pustaka

Format APA 7. Tanda di depan setiap entri menunjukkan tingkat pengecekan (lihat bagian 2).

Model penelitian dan pengembangan

K Branch, R. M. (2009). *Instructional design: The ADDIE approach*. Springer. https://doi.org/10.1007/978-0-387-09506-6 (isi: C)

C Borg, W. R., & Gall, M. D. (1983). *Educational research: An introduction* (4th ed.). Longman.

K Gall, M. D., Gall, J. P., & Borg, W. R. (2003). *Educational research: An introduction* (7th ed.). Allyn & Bacon.

C Luther, A. C. (1994). *Authoring interactive multimedia*. AP Professional.

K McKenney, S., & Reeves, T. C. (2019). *Conducting educational design research* (2nd ed.). Routledge. https://doi.org/10.4324/9781315105642

C Nieveen, N. (1999). Prototyping to reach product quality. In J. van den Akker, R. M. Branch, K. Gustafson, N. Nieveen, & T. Plomp (Eds.), *Design approaches and tools in education and training* (pp. 125–135). Kluwer Academic. https://doi.org/10.1007/978-94-011-4255-7_10

A Nieveen, N., & Folmer, E. (2013). Formative evaluation in educational design research. In T. Plomp & N. Nieveen (Eds.), *Educational design research – Part A: An introduction* (pp. 152–169). SLO.

A Plomp, T. (2013). Educational design research: An introduction. In T. Plomp & N. Nieveen (Eds.), *Educational design research – Part A: An introduction* (pp. 10–51). SLO. https://www.slo.nl/publish/pages/2904/educational-design-research-part-a.pdf

K Ramadan, R., & Widyani, Y. (2013). Game development life cycle guidelines. In *2013 International Conference on Advanced Computer Science and Information Systems (ICACSIS)* (pp. 95–100). IEEE. https://doi.org/10.1109/ICACSIS.2013.6761558 (fase: S Aleem dkk., 2016)

K Richey, R. C., & Klein, J. D. (2007). *Design and development research: Methods, strategies, and issues*. Lawrence Erlbaum Associates. https://doi.org/10.4324/9780203826034

A Sugiyono. (2013). *Metode penelitian kuantitatif, kualitatif, dan R&D* (cet. ke-19). Alfabeta.

K Sugiyono. (2015). *Metode penelitian dan pengembangan (research and development): Untuk bidang pendidikan, manajemen, sosial, dan teknik*. Alfabeta.

C Tessmer, M. (1993). *Planning and conducting formative evaluations: Improving the quality of education and training*. Kogan Page. Terbitan ulang Routledge: https://doi.org/10.4324/9780203061978

A Thiagarajan, S., Semmel, D. S., & Semmel, M. I. (1974). *Instructional development for training teachers of exceptional children: A sourcebook*. Center for Innovation in Teaching the Handicapped, Indiana University. https://eric.ed.gov/?id=ED090725

C van den Akker, J. (1999). Principles and methods of development research. In J. van den Akker, R. M. Branch, K. Gustafson, N. Nieveen, & T. Plomp (Eds.), *Design approaches and tools in education and training* (pp. 1–14). Kluwer Academic. https://doi.org/10.1007/978-94-011-4255-7_1 (hlm. 9: S Plomp, 2013, hlm. 24)

Asesmen, validitas, dan analisis

K Adams, R. J., Wilson, M., & Wang, W.-C. (1997). The multidimensional random coefficients multinomial logit model. *Applied Psychological Measurement, 21*(1), 1–23. https://doi.org/10.1177/0146621697211001 (istilah *between/within-item*: S Briggs & Wilson, 2003)

A Almond, R. G., Steinberg, L. S., & Mislevy, R. J. (2002). Enhancing the design and delivery of assessment systems: A four-process architecture. *Journal of Technology, Learning, and Assessment, 1*(5). https://ejournals.bc.edu/index.php/jtla/article/view/1671

A American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). *Standards for educational and psychological testing*. American Educational Research Association.

K Bond, T. G., & Fox, C. M. (2015). *Applying the Rasch model: Fundamental measurement in the human sciences* (3rd ed.). Routledge. https://doi.org/10.4324/9781315814698

A Campbell, D. T., & Stanley, J. C. (1963). *Experimental and quasi-experimental designs for research*. Rand McNally.

K Kane, M. T. (2013). Validating the interpretations and uses of test scores. *Journal of Educational Measurement, 50*(1), 1–73. https://doi.org/10.1111/jedm.12000

A Linacre, J. M. (2002). What do infit and outfit, mean-square and standardized mean? *Rasch Measurement Transactions, 16*(2), 878. https://www.rasch.org/rmt/rmt162f.htm

A Messick, S. (1995). Validity of psychological assessment: Validation of inferences from persons' responses and performances as scientific inquiry into score meaning. *American Psychologist, 50*(9), 741–749. https://doi.org/10.1037/0003-066X.50.9.741 (isi dibaca dari versi laporan ETS RR-94-45)

A Mislevy, R. J., & Haertel, G. D. (2006). Implications of evidence-centered design for educational testing. *Educational Measurement: Issues and Practice, 25*(4), 6–20. https://doi.org/10.1111/j.1745-3992.2006.00075.x

A Mislevy, R. J., Steinberg, L. S., & Almond, R. G. (2003). On the structure of educational assessments. *Measurement: Interdisciplinary Research and Perspectives, 1*(1), 3–62. https://doi.org/10.1207/S15366359MEA0101_02 (halaman yang dikutip dari versi laporan CRESST CSE 597)

A Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences, 115*(11), 2600–2606. https://doi.org/10.1073/pnas.1708274114

K Shadish, W. R., Cook, T. D., & Campbell, D. T. (2002). *Experimental and quasi-experimental designs for generalized causal inference*. Houghton Mifflin.

A Shute, V. J. (2011). Stealth assessment in computer-based games to support learning. In S. Tobias & J. D. Fletcher (Eds.), *Computer games and instruction* (pp. 503–524). Information Age Publishing.

K Shute, V. J., & Ventura, M. (2013). *Stealth assessment: Measuring and supporting learning in video games*. MIT Press. https://doi.org/10.7551/mitpress/9589.001.0001

K Singer, J. D., & Willett, J. B. (2003). *Applied longitudinal data analysis: Modeling change and event occurrence*. Oxford University Press. https://doi.org/10.1093/acprof:oso/9780195152968.001.0001

K Wilson, M. (2005). *Constructing measures: An item response modeling approach*. Lawrence Erlbaum Associates. https://doi.org/10.4324/9781410611697

A Wise, S. L., & Kong, X. (2005). Response time effort: A new measure of examinee motivation in computer-based tests. *Applied Measurement in Education, 18*(2), 163–183. https://doi.org/10.1207/s15324818ame1802_2

Validasi ahli, pengamatan, dan media

K Aiken, L. R. (1985). Three coefficients for analyzing the reliability and validity of ratings. *Educational and Psychological Measurement, 45*(1), 131–142. https://doi.org/10.1177/0013164485451012 (rumus V: S Merino & Livia, 2009, hlm. 170)

K Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46. https://doi.org/10.1177/001316446002000104

K Cohen, J. (1968). Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit. *Psychological Bulletin, 70*(4), 213–220. https://doi.org/10.1037/h0026256

K Ericsson, K. A., & Simon, H. A. (1993). *Protocol analysis: Verbal reports as data* (Rev. ed.). MIT Press. https://doi.org/10.7551/mitpress/5657.001.0001

A Leacock, T. L., & Nesbit, J. C. (2007). A framework for evaluating the quality of multimedia learning resources. *Educational Technology & Society, 10*(2), 44–59.

K Lynn, M. R. (1986). Determination and quantification of content validity. *Nursing Research, 35*(6), 382–385. https://doi.org/10.1097/00006199-198611000-00017 (aturannya: S Polit & Beck, 2006, hlm. 491)

K Nielsen, J. (1994a). Heuristic evaluation. In J. Nielsen & R. L. Mack (Eds.), *Usability inspection methods* (pp. 25–62). John Wiley & Sons.

A Nielsen, J. (1994b, November 1). *Severity ratings for usability problems*. Nielsen Norman Group. https://www.nngroup.com/articles/how-to-rate-the-severity-of-usability-problems/

A Ocumpaugh, J., Baker, R. S., & Rodrigo, M. M. T. (2015). *Baker Rodrigo Ocumpaugh Monitoring Protocol (BROMP) 2.0 technical and training manual*. Teachers College, Columbia University; Ateneo Laboratory for the Learning Sciences.

A Polit, D. F., & Beck, C. T. (2006). The content validity index: Are you sure you know what's being reported? Critique and recommendations. *Research in Nursing & Health, 29*(5), 489–497. https://doi.org/10.1002/nur.20147

A Polit, D. F., Beck, C. T., & Owen, S. V. (2007). Is the CVI an acceptable indicator of content validity? Appraisal and recommendations. *Research in Nursing & Health, 30*(4), 459–467. https://doi.org/10.1002/nur.20199

A Wahono, R. S. (2006, 21 Juni). Aspek dan kriteria penilaian media pembelajaran. *RomiSatriaWahono.Net*. https://romisatriawahono.net/2006/06/21/aspek-dan-kriteria-penilaian-media-pembelajaran/

Teori dan kerangka

K Alwasilah, A. C., Suryadi, K., & Karyono, T. (2009). *Etnopedagogi: Landasan praktek pendidikan dan pendidikan guru*. Kiblat Buku Utama. (tahun 2009 dan definisinya: S Rahayu dkk., 2021, hlm. 137)

K Anderson, L. W., & Krathwohl, D. R. (Eds.). (2001). *A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives*. Longman.

K Biggs, J. B., & Collis, K. F. (1982). *Evaluating the quality of learning: The SOLO taxonomy (Structure of the Observed Learning Outcome)*. Academic Press. https://doi.org/10.1016/C2013-0-10375-3

A Cosgrove, J., & Cachia, R. (2025). *DigComp 3.0: European digital competence framework* (5th ed.). Publications Office of the European Union. https://doi.org/10.2760/0001149

K Csikszentmihalyi, M. (1990). *Flow: The psychology of optimal experience*. Harper & Row.

K Freire, M., Serrano-Laguna, Á., Manero Iglesias, B., Martínez-Ortiz, I., Moreno-Ger, P., & Fernández-Manjón, B. (2016). Game learning analytics: Learning analytics for serious games. In J. M. Spector, B. B. Lockee, & M. D. Childress (Eds.), *Learning, design, and technology: An international compendium of theory, research, practice, and policy* (pp. 1–29). Springer. https://doi.org/10.1007/978-3-319-17727-4_21-1

K Gay, G. (2018). *Culturally responsive teaching: Theory, research, and practice* (3rd ed.). Teachers College Press.

K Gee, J. P. (2003). *What video games have to teach us about learning and literacy*. Palgrave Macmillan.

K Gilster, P. (1997). *Digital literacy*. Wiley.

K Hattie, J., & Timperley, H. (2007). The power of feedback. *Review of Educational Research, 77*(1), 81–112. https://doi.org/10.3102/003465430298487

A Kementerian Komunikasi dan Informatika & Katadata Insight Center. (2023). *Status literasi digital di Indonesia 2022*. https://cdn1.katadata.co.id/media/microsites/litdik/ReportSurveiStatusLiterasiDigitalIndonesia2022.pdf

K Malone, T. W. (1981). Toward a theory of intrinsically motivating instruction. *Cognitive Science*, *5*(4), 333–369. https://doi.org/10.1207/s15516709cog0504_2

A Malone, T. W., & Lepper, M. R. (1987). Making learning fun: A taxonomy of intrinsic motivations for learning. In R. E. Snow & M. J. Farr (Eds.), *Aptitude, learning, and instruction: Vol. 3. Conative and affective process analyses* (pp. 223–253). Lawrence Erlbaum Associates.

K Mayer, R. E. (2021). *Multimedia learning* (3rd ed.). Cambridge University Press. https://doi.org/10.1017/9781316941355 (penerbit mencatat terbit daring 2020)

K Shute, V. J. (2008). Focus on formative feedback. *Review of Educational Research*, *78*(1), 153–189. https://doi.org/10.3102/0034654307313795

A von Davier, M., & Kennedy, A. (Eds.). (2024). *PIRLS 2026 assessment frameworks*. TIMSS & PIRLS International Study Center, Boston College. https://doi.org/10.6017/lse.tpisc.tr2103.kb4199

A Webb, N. L. (1997). *Criteria for alignment of expectations and assessments in mathematics and science education* (Research Monograph No. 6). National Institute for Science Education; Council of Chief State School Officers. https://eric.ed.gov/?id=ED414305

A Webb, N. L. (1999). *Alignment of science and mathematics standards and assessments in four states* (Research Monograph No. 18). https://eric.ed.gov/?id=ED440852

Sumber sekunder dan contoh pemakaian di Indonesia

Dipakai hanya untuk klaim yang ditandai S, atau sebagai contoh pemakaian model Plomp. Halaman jurnalnya dibuka; data bibliografi di bawah adalah yang terlihat di halaman itu.

Aleem, S., Capretz, L. F., & Ahmed, F. (2016). *Journal of Software Engineering Research and Development*, *4*(6). https://doi.org/10.1186/s40411-016-0032-7

Briggs, D. C., & Wilson, M. (2003). *Journal of Applied Measurement*, *4*(1), hlm. 98, catatan 1–2.

Merino, C., & Livia, J. (2009). *Anales de Psicología*, hlm. 170. https://revistas.um.es/analesps/article/view/71631

Rahayu dkk. (2021). *Jurnal Ilmiah P2M STKIP Siliwangi*, *8*(2), hlm. 137. https://e-journal.stkipsiliwangi.ac.id/index.php/p2m/article/view/2963

Ferita & Retnawati (2016). *Pythagoras*, *11*(1), 69–76. https://jurnal.uny.ac.id/index.php/pythagoras/article/view/9672

Djidu & Jailani (2018). *Jurnal Kependidikan*, *2*(1), 68–84. https://jurnal.uny.ac.id/index.php/jk/article/view/12689

Siregar dkk. (2021). *JKPM*, *7*(1). https://journal.lppmunindra.ac.id/index.php/jkpm/article/view/11365

Fitrianty dkk. (2022). *Lattice*, *2*(1), 91–102. https://ejournal.uinbukittinggi.ac.id/lattice/article/view/5337

Wardhani (2024). *Widyagogik*. https://journal.trunojoyo.ac.id/widyagogik/article/view/26052